DESARROLLO DE AI

Grupo:

Integrantes:
Cristobal Diaz
Lucas Nestler
Juan de la Cuadra

Profesor:

5 de Mayo de 2026

Modelos

Para este trabajo se diseñaron y entrenaron 5 arquitecturas distintas de redes neuronales en TensorFlow/Keras. El formato de entrada es común a todas: imágenes de 128×128 píxeles con 1 canal de color, procesadas en int8. Con el fin de evaluar la viabilidad de despliegue en el ESP32, cada modelo fue exportado a TFLite aplicando cuantización completa int8.

Modelo	Tipo	Parámetros	Tamaño TFLite (KB)	Operaciones	Val. Accuracy
Topología 1	Fully Connected	524,353	515.91	1.0486 MFLOPs	70.21%
Topología 2	CNN Simple	31,833	34.77	2.3496 MFLOPs	76.60%
Topología 3	CNN 2 capas	33,601	38.45	38.9226 MFLOPs	80.85%
Topología 4	CNN Simple ½ filtros	63,665	66.08	4.6993 MFLOPs	78.72%
Topología 5	CNN 2 capas ½ filtros	15,649	20.29	10.8881 MFLOPs	82.98%

La Topología T1 es de tipo Fully Connected (FC). Recibe la imagen aplanada como vector de 16.384 elementos (128x128), lo que genera 524,353 parámetros y un tamaño estimado de 2,048.25 KB, superando el límite de Flash del ESP32. Las Topologías T2 a T5 son de tipo CNN y explotan la estructura espacial de la imagen mediante convoluciones locales, reduciendo drásticamente el número de parámetros — T5_CNN_Doble_MaxPooling es el modelo más compacto con solo 15,649 parámetros y 20,29 KB.

Topología 1: Fully Connected

- Training Accuracy: 98.50%
- Validation Accuracy: 70.21%
- Tamaño estimado: 2048.25 KB
- Tamaño cuantizado: 515.91 KB
- Operaciones: 1.0486 MFLOPs

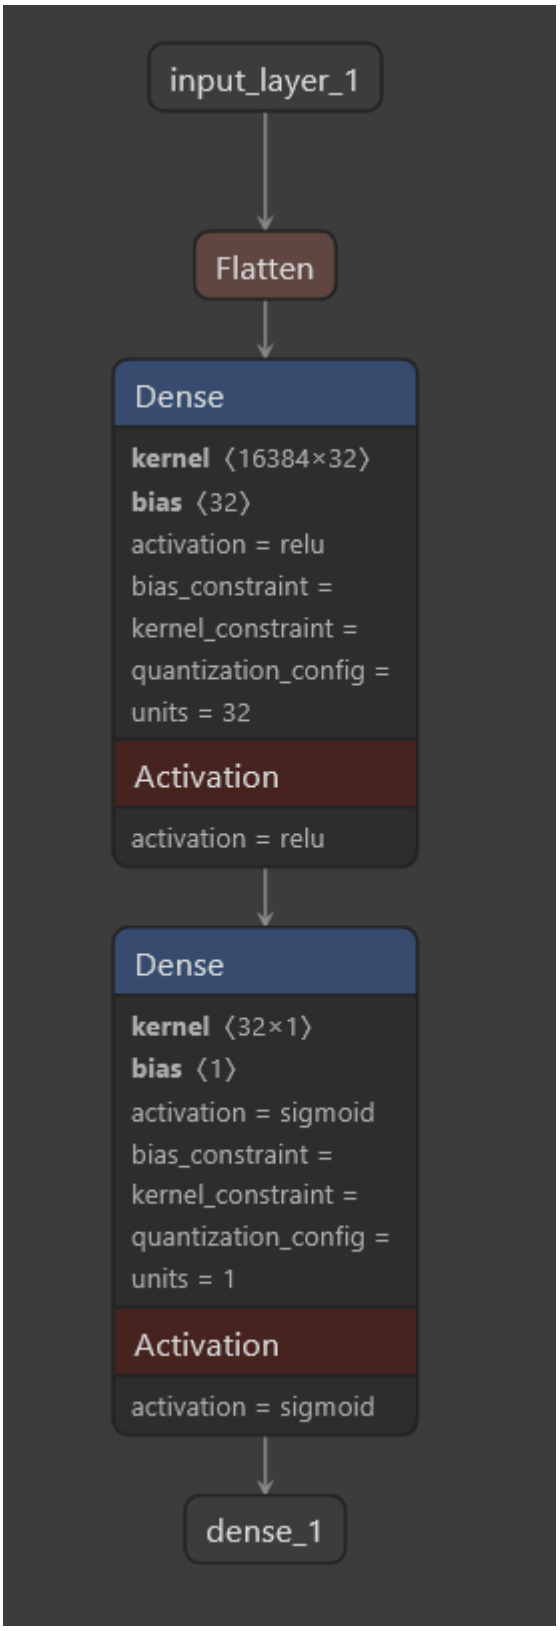

Topología 2: CNN Simple

- Training Accuracy: 100.00%
- Validation Accuracy: 76.60%
- Tamaño estimado: 124.35 KB
- Tamaño cuantizado: 34.77 KB
- Operaciones: 2.3496 MFLOPs

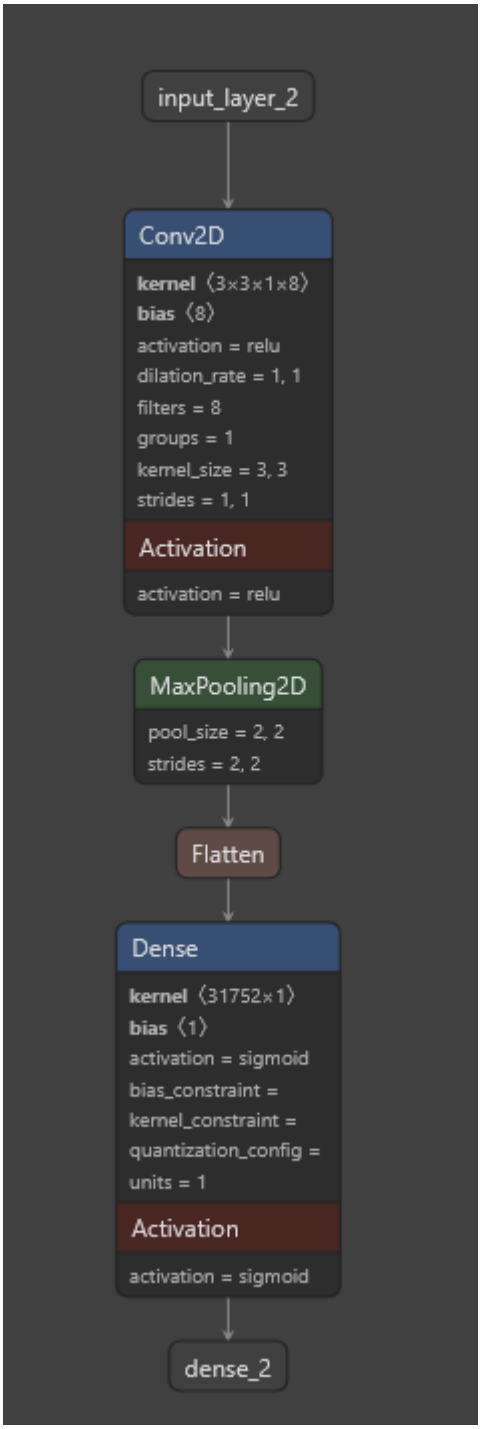

Topología 3: CNN de 2 capas

- Training Accuracy: 100.00%
- Validation Accuracy: 80.85%
- Tamaño estimado: 131.25 KB
- Tamaño cuantizado: 38.45 KB
- Operaciones: 38.9226 MFLOPs

Topología 4: CNN Simple con mitad de filtros

- Training Accuracy: 99.50%
- Validation Accuracy: 78.72%
- Tamaño estimado: 248.69 KB
- Tamaño cuantizado: 66.08 KB
- Operaciones: 4.6993 MFLOPs

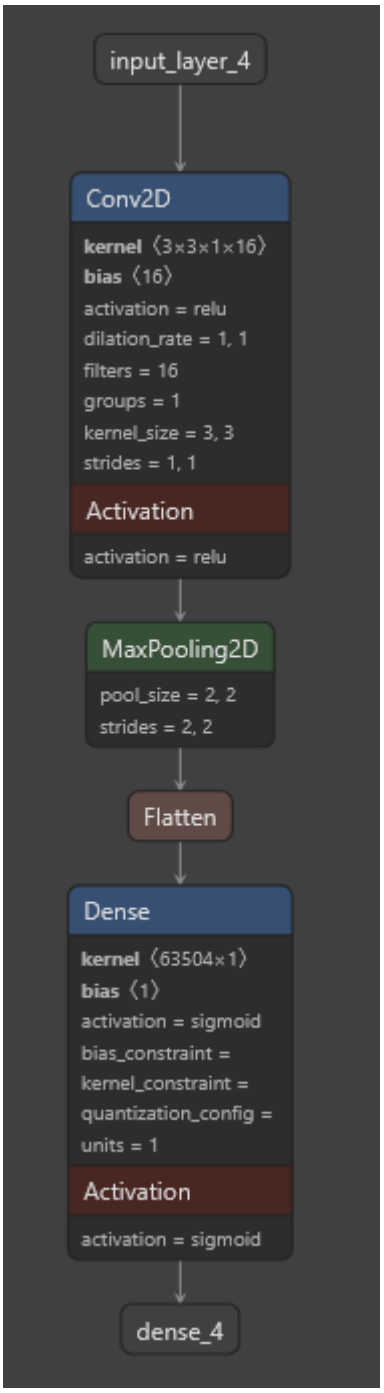

Topología 5: CNN de 2 capas con mitad de filtros

- Training Accuracy: 100.00%
- Validation Accuracy: 82.98%
- Tamaño estimado: 61.13 KB
- Tamaño cuantizado: 20.29 KB
- Operaciones: 10.8881 MFLOPs

Tipo	MACs (M)	Latencia Estimada (ms)	FPS Estimado	Potencia Estimada (mW)	RAM (KB)
Fully Connected	0.5243	448.6	2.23	396	16.4
CNN Simple	1.2114	1036.4	0.96	396	131.1
CNN 2 capas	21.2625	18191.1	0.05	396	262.1
CNN Simple ½ filtros	2.4228	2072.8	0.48	396	262.1
CNN 2 capas ½ filtros	5.9126	5058.5	0.20	396	131.1

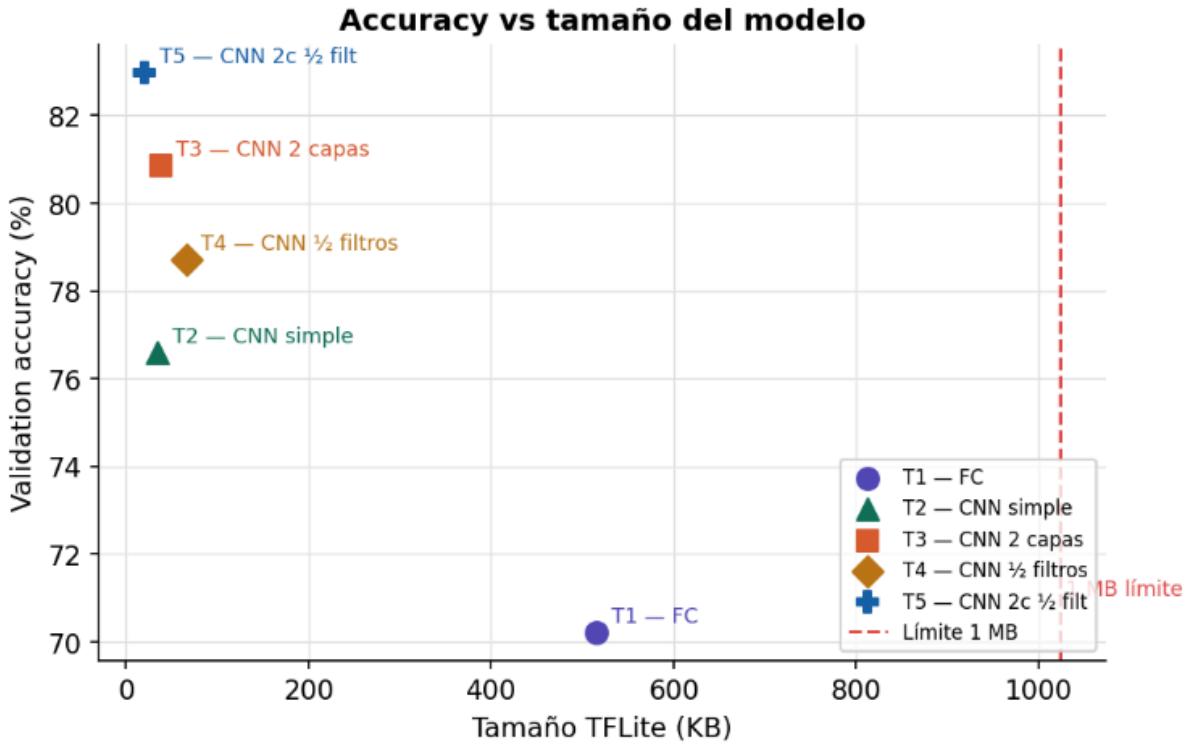

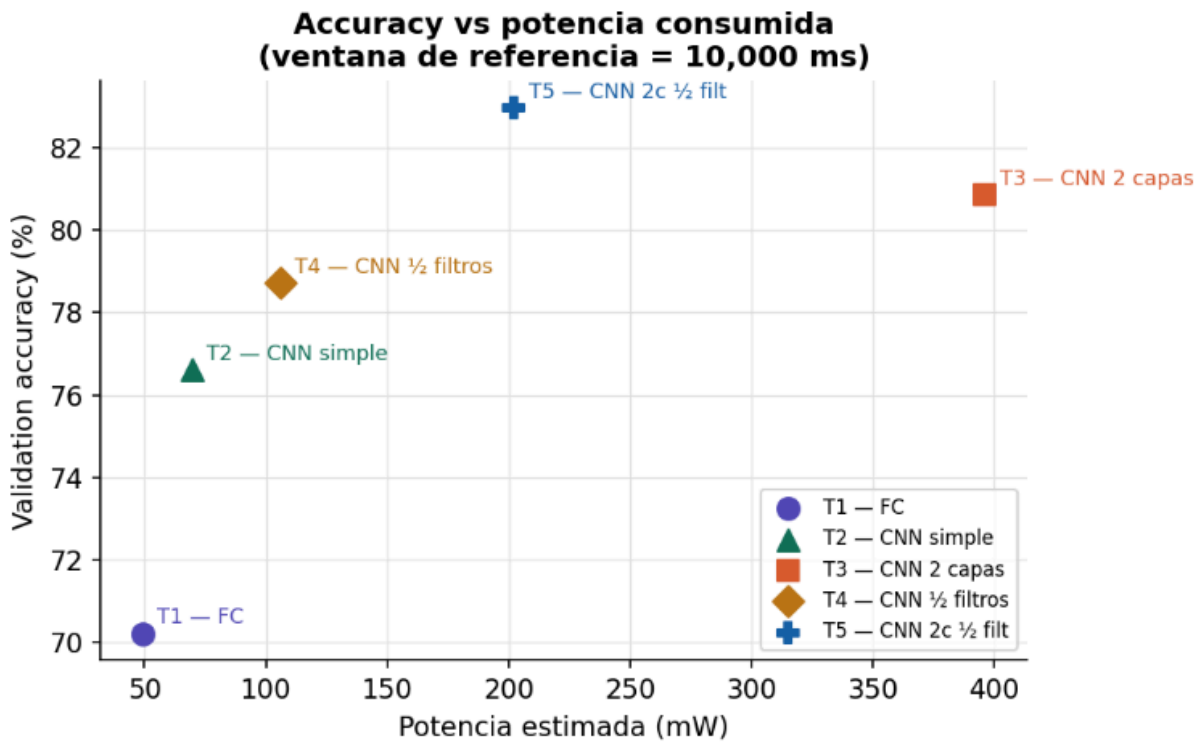
Accuracy vs potencia consumida
(ventana de referencia = 10,000 ms)
T5 — CNN 2c ½ filt
T3 — CNN 2 capas
T4 — CNN ½ filtros
T2 — CNN simple
T1 — FC
T1 — FC
T2 — CNN simple
T3 — CNN 2 capas
T4 — CNN ½ filtros
T5 — CNN 2c ½ filt
Validation accuracy (%)
Potencia estimada (mW)
70
72
74
76
78
80
82
50
100
150
200
250
300
350
400

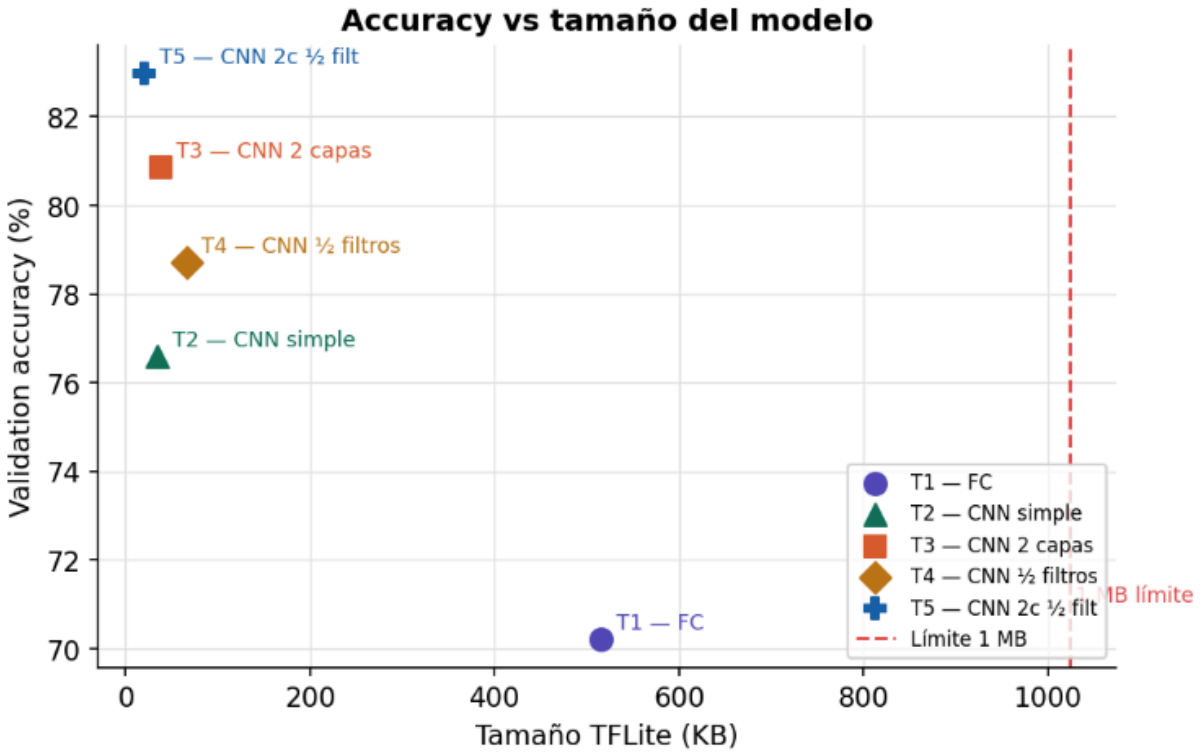
Accuracy vs tamaño del modelo
T5 — CNN 2c ½ filt
T3 — CNN 2 capas
T4 — CNN ½ filtros
T2 — CNN simple
T1 — FC
T1 — FC
T2 — CNN simple
T3 — CNN 2 capas
T4 — CNN ½ filtros
T5 — CNN 2c ½ filt
Límite 1 MB
MB límite
Validation accuracy (%)
Tamaño TFLite (KB)
70
72
74
76
78
80
82
0
200
400
600
800
1000

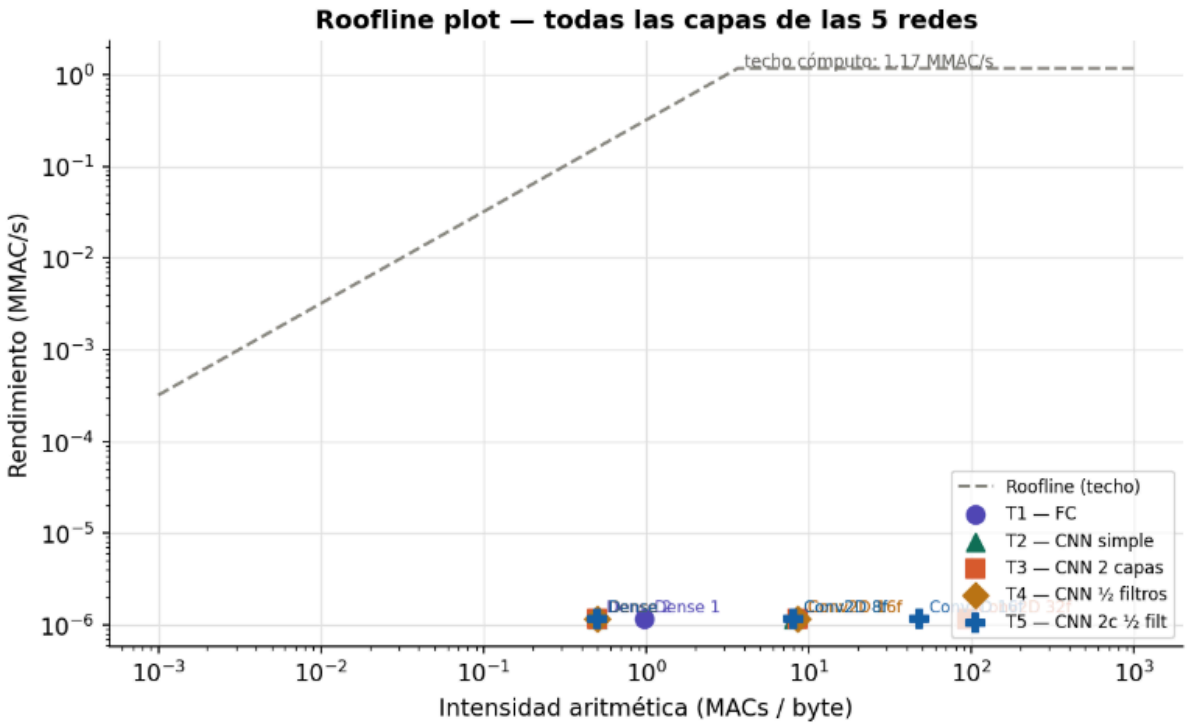
Roofline plot — todas las capas de las 5 redes
techo cómputo: 1.17 MMAC/s
Rendimiento (MMAC/s)
Intensidad aritmética (MACs / byte)
Roofline (techo)
T1 — FC
T2 — CNN simple
T3 — CNN 2 capas
T4 — CNN ½ filtros
T5 — CNN 2c ½ filt
Dense 1