

# **DESARROLLO DE AI**

Laboratorio 2 - Sistemas Embebidos

Integrantes:

Cristóbal Díaz

Lucas Nestler

Juan de la Cuadra

5 de mayo de 2026

**Links Dataset:****Fotos con Objeto**

<https://drive.google.com/drive/folders/12XrTw82dcrk7DHU8n0cj63Q8O8pMGhVg?usp=sharing>

**Fotos sin Objeto**

<https://drive.google.com/drive/folders/178a2nUIYLh1llwW27aXKygtf-D1B1V5a?usp=sharing>

## 1. Modelos entrenados

Para este trabajo se diseñaron y entrenaron 5 arquitecturas distintas de redes neuronales utilizando TensorFlow/Keras. El formato de entrada es común a todas: imágenes de 128×128 píxeles con 1 canal de color (escala de grises), procesadas en int8. Con el fin de evaluar la viabilidad de despliegue en el ESP32-CAM, cada modelo fue exportado a TFLite aplicando cuantización completa int8, lo que reduce el tamaño en memoria y permite correr inferencia en hardware embebido sin unidad de punto flotante.

| Modelo      | Tipo                  | Parámetros | Tamaño TFLite (KB) | Operaciones    | Val. Accuracy |
|-------------|-----------------------|------------|--------------------|----------------|---------------|
| Topología 1 | Fully Connected       | 524,353    | 515.91             | 1.0486 MFLOPs  | 70.21%        |
| Topología 2 | CNN Simple            | 31,833     | 34.77              | 2.3496 MFLOPs  | 76.60%        |
| Topología 3 | CNN 2 capas           | 33,601     | 38.45              | 38.9226 MFLOPs | 80.85%        |
| Topología 4 | CNN Simple ½ filtros  | 63,665     | 66.08              | 4.6993 MFLOPs  | 78.72%        |
| Topología 5 | CNN 2 capas ½ filtros | 15,649     | 20.29              | 10.8881 MFLOPs | 82.98%        |

La Topología T1 es de tipo Fully Connected (FC). Recibe la imagen aplanada como vector de 16.384 elementos (128×128), lo que genera 524.353 parámetros y un tamaño cuantizado de 515.91 KB. Aunque cabe en la Flash del ESP32, su accuracy de validación es la más baja (70.21%), lo que indica sobreajuste severo. El modelo memoriza el set de entrenamiento pero no generaliza bien.

Las Topologías T2 a T5 son de tipo CNN y explotan la estructura espacial de la imagen mediante convoluciones locales, reduciendo drásticamente el número de parámetros. La Topología 5 (CNN de 2 capas con mitad de filtros) es el modelo más compacto con solo 15.649 parámetros y 20.29 KB, y al mismo tiempo el de mayor accuracy de validación (82.98%), lo que la convierte en la candidata principal para despliegue.



## 2. Estimación en el ESP32

### 2.1 Metodología

Para estimar la latencia de inferencia en el ESP32-CAM, se midió directamente el tiempo total de ejecución de la Topología 5 utilizando la función `micros()`, que mide el tiempo transcurrido en microsegundos. Esta llamada ejecuta el modelo completo de principio a fin, todas las capas convolucionales, pooling, flatten y dense.

El resultado obtenido fue:

$$\text{Latencia medida (T5)} = 4.657.645 \mu\text{s} \approx 4.657 \text{ ms} \rightarrow 0.21 \text{ FPS}$$

A partir de esta medición se derivó una velocidad efectiva de cómputo del ESP32-CAM de:

$$\text{Velocidad efectiva} = \text{MACs\_T5} / \text{Latencia\_T5} = 5.444\text{M} / 4.657 \text{ s} \approx 1.17 \text{ MMAC/s}$$

Este valor refleja el rendimiento real del procesador, ejecutando TFLite Micro con pesos int8 en PSRAM, incluyendo el overhead de transferencia de memoria entre PSRAM y cache interna. Es significativamente menor al techo teórico (120 MMAC/s) porque el bottleneck es el ancho de banda de la PSRAM y no la capacidad aritmética del procesador.

Las latencias de las demás topologías se estimaron escalando proporcionalmente a sus MACs totales:

$$\text{Latencia\_X} = \text{MACs\_X} / 1.17 \text{ MMAC/s}$$

### 2.2 Movimiento de memoria

El movimiento de memoria por capa se calculó sumando los bytes leídos y escritos durante cada operación del forward pass. Para las capas convolucionales se consideran el tensor de entrada, el tensor de salida y los pesos del kernel (todo en int8, 1 byte por valor). Para las capas Dense se incluyen la entrada, los pesos y la salida. Las capas MaxPool y Flatten solo mueven activaciones.

La RAM de activaciones reportada corresponde al tensor de activación más grande que existe en memoria durante el forward pass, lo que determina el pico de uso de memoria dinámica del modelo.

### 2.3 FPS y potencia estimada

Los FPS se calculan como el inverso de la latencia. La potencia se estima usando un *duty cycle* sobre una ventana de referencia de 10.000 ms (0.1 FPS objetivo), que es representativa de las latencias reales medidas. Se usa un perfil de corriente de 120 mA en operación activa y 10 mA en reposo, a 3.3 V:

$$\text{DC} = \min(\text{Latencia} / 10.000 \text{ ms}, 1.0) \quad | \quad I = 120 \cdot \text{DC} + 10 \cdot (1 - \text{DC}) \quad | \quad P = I \times 3.3 \text{ V}$$

| Topología           | MACs (M) | Latencia est. (ms) | FPS estimado | Potencia (mW) | RAM pico (KB) |
|---------------------|----------|--------------------|--------------|---------------|---------------|
| T1 -Fully Connected | 0.524    | 448.6              | 2.23         | 43            | 16.4          |

| Topología                | MACs (M) | Latencia est. (ms) | FPS estimado | Potencia (mW) | RAM pico (KB) |
|--------------------------|----------|--------------------|--------------|---------------|---------------|
| T2 -CNN Simple           | 1.175    | 1,005.4            | 0.99         | 99            | 131.1         |
| T3 -CNN 2 capas          | 19.461   | 16,644.7           | 0.06         | 396           | 262.1         |
| T4 -CNN Simple ½ filtros | 2.350    | 2,010.8            | 0.50         | 176           | 262.1         |
| T5 -CNN 2c ½ filtros     | 5.444    | 4,657.0            | 0.21         | 259           | 131.1         |


Tabla 1. Estimación de latencia, FPS y potencia para las 5 topologías.

Notar que T3 (CNN 2 capas con filtros completos) tiene un duty cycle del 100%, la latencia supera la ventana de referencia por lo que el procesador nunca descansa entre inferencias y consume la potencia máxima de 396 mW. En el otro extremo, T1 (FC) es la de menor potencia (43 mW) porque termina rápido y el procesador está ocioso la mayor parte del tiempo, aunque esto viene al costo de la peor accuracy.

### 3. Análisis de resultados

#### 3.1 Accuracy vs tamaño del modelo


El siguiente gráfico muestra el accuracy de validación de cada topología en función de su tamaño cuantizado en KB. La línea roja punteada indica el límite conservador de 1 MB para el despliegue en el ESP32.



Todas las topologías CNN (T2 a T5) caben holgadamente bajo el límite de 1 MB, con tamaños entre 20 y 66 KB. T1 (515 KB) también cabe pero ofrece la peor accuracy. Destaca que T5 logra el mayor accuracy (82.98%) con el menor tamaño (20.29 KB), siendo claramente la mejor opción en esta dimensión.


### 3.2 Accuracy vs FPS estimado

Este gráfico permite evaluar el trade off entre velocidad de inferencia y precisión. Un mayor FPS es deseable para aplicaciones en tiempo real como la detección de identificadores de robots sumo en movimiento.



T2 (CNN Simple) es la más rápida (1 FPS) pero sacrifica accuracy. T3 es extremadamente lenta (0.06 FPS) sin ofrecer una mejora de accuracy suficiente para justificarlo. T5 ofrece 0.21 FPS con la mayor accuracy, lo que en el contexto del sistema es aceptable dado que el robot sumo no necesita inferencia a alta velocidad para detectar identificadores estáticos.


### 3.3 Accuracy vs potencia consumida



T5 consume 259 mW, valor intermedio entre T2 (99 mW) y T3 (396 mW). La diferencia de potencia entre T5 y T2 es de ~160 mW, lo que en términos de batería tiene impacto moderado. Dado que la mejora de accuracy de T5 sobre T2 es de 6.38 puntos porcentuales, el mayor consumo está justificado.

### 3.4 Roofline plot

El Roofline plot muestra el rendimiento real de cada capa (MMAC/s) en función de su intensidad aritmética (MACs por byte movido). La línea punteada representa el techo de cómputo medido (1.17 MMAC/s). Las capas que se encuentran por debajo y a la izquierda del punto de quiebre son memory bound su rendimiento está limitado por el ancho de banda de memoria, no por la capacidad aritmética del procesador.



Todas las capas se encuentran en la zona memory-bound del Roofline, lo que confirma que el cuello de botella del sistema es el ancho de banda entre la PSRAM y el procesador, y no la capacidad de cómputo del Xtensa LX6. Las capas Dense de T1 y T4 tienen alta intensidad aritmética (muchos MACs por byte) pero aun así están por debajo del techo esto se debe a que la PSRAM es inherentemente lenta (10-20 MB/s efectivos) comparada con la SRAM interna. Las capas Conv2D tienen menor intensidad aritmética y también están limitadas por memoria, lo que es consistente con kernels pequeños (3×3) sobre imágenes de entrada grandes.

Este análisis indica que para mejorar el rendimiento en el ESP32-CAM, la estrategia más efectiva no sería aumentar la frecuencia del CPU, sino reducir el movimiento de memoria por ejemplo, usando modelos más pequeños, aplicando pruning, o reduciendo la resolución de entrada.

#### 4. Red seleccionada

Considerando el análisis conjunto de los cuatro gráficos y los datos de la Tabla 1, la red seleccionada para el despliegue en el ESP32-CAM es la Topología 5: CNN de 2 capas con mitad de filtros.

Los argumentos que sustentan esta decisión son:

- Mayor accuracy de validación (82.98%), que es el criterio principal para el objetivo de detección.
- Modelo más compacto (20.29 KB cuantizado), dejando amplio margen de Flash para el resto del firmware.



- Menor número de parámetros (15.649), lo que reduce el riesgo de sobreajuste y mejora la generalización a condiciones nuevas.
- Potencia de 259 mW

T3 (CNN 2 capas, filtros completos) ofrece solo 2.13 puntos porcentuales más de accuracy que T5 en training pero con un costo de 16× más operaciones y prácticamente el doble de RAM de activaciones un trade off que no se justifica en hardware tan restringido. T2 es la segunda mejor opción si la velocidad fuera prioritaria, pero su accuracy inferior (76.60%) representaría un riesgo de falsos negativos en la detección del identificador adversario durante la competencia.